

Classificação de Células Cervicais em Imagens de Citologia Baseada em Redes Neurais Convolucionais

Alan Teixeira da Costa

Universidade Federal do Espírito Santo
Vitória, Brasil

Miguel Vieira Machado Pim

Universidade Federal do Espírito Santo
Vitória, Brasil

Pedro Henrique Bravim Duarte

Universidade Federal do Espírito Santo
Vitória, Brasil

Abstract—O câncer do colo do útero é um desafio significativo para a saúde pública mundial, tornando a detecção precoce por meio do exame de Papanicolaou crucial para o sucesso do tratamento. A classificação automatizada de células via aprendizado profundo surge como uma alternativa promissora para otimizar o diagnóstico e reduzir a dependência da avaliação manual. Este trabalho propõe uma abordagem baseada na arquitetura pré-treinada EfficientNet-B3, empregando estratégias de ajuste fino total e técnicas de regularização para mitigar variações de coloração entre lâminas. O método foi avaliado de forma robusta no conjunto de dados público CRIC em cenários de classificação binária, de três e de seis classes, utilizando validação cruzada e uma combinação de predições por comitê de modelos (ensemble). Os resultados obtidos demonstram alta acurácia e consistência estatística, confirmando a robustez do modelo e sua viabilidade como ferramenta de suporte ao rastreamento cervical automatizado frente a métodos do estado da arte.

Index Terms—Aprendizado profundo, câncer do colo do útero, classificação de imagens, conjunto de dados CRIC, EfficientNet-B3, ensemble

I. INTRODUÇÃO

O câncer do colo do útero é uma neoplasia que acomete um número expressivo de mulheres em todo o mundo. Em 2024, foram registrados aproximadamente 603.890 novos casos e 279.437 mortes em decorrência dessa doença [1]. No entanto, a detecção precoce aliada ao tratamento adequado pode elevar as chances de cura para cerca de 92% [2]. O exame de Papanicolaou (*Pap smear*) [3] é um dos métodos mais utilizados globalmente para o rastreio da doença, especialmente em países de baixa e média renda [2], devido à sua eficácia e ao seu baixo custo relativo.

Apesar de sua adoção em larga escala, o método apresenta limitações. A eficácia do exame depende da intervenção de profissionais altamente especializados e demanda tempo considerável para a avaliação de cada lâmina [4], exigindo rigor metodológico para garantir resultados precisos [5]. Diante desses desafios, a literatura científica tem reportado um número crescente de pesquisas voltadas à automatização da análise desses exames, visando otimizar o diagnóstico e reduzir a dependência da avaliação manual.

O aprendizado de máquina (*Machine Learning*) é um campo que tem fornecido soluções inovadoras para diversas áreas, com destaque para a saúde [6]. Dessa forma, essa tecnologia representa uma via promissora para suprir a demanda por

análises automatizadas de células cervicais. Nesse contexto, a literatura apresenta trabalhos como o de [7], que utilizam técnicas como *Support Vector Machine* (SVM), *K-Nearest Neighbors* (KNN) e *Random Forest* (RF) para a classificação de lesões no colo do útero.

Como uma subárea do aprendizado de máquina, o aprendizado profundo (*Deep Learning*) ganha destaque por empregar redes neurais multicamadas capazes de extrair representações complexas dos dados de forma mais robusta. Nesse cenário, o estudo de [8] aplica redes neurais convolucionais (CNNs, do inglês *Convolutional Neural Networks*) pré-treinadas em conjunto com um mecanismo de *ensemble* para classificar tais lesões. Por sua vez, [9] propõem uma abordagem baseada em uma rede de fusão de características (*feature fusion network*), combinando vetores de características extraídos de duas arquiteturas pré-treinadas distintas: VGG16 e ResNet50.

Diante disso, este trabalho propõe a utilização da arquitetura CNN pré-treinada *EfficientNet-B3* [10], empregando uma estratégia de ajuste fino total associada a técnicas de regularização como *label smoothing* e perturbação de cor para mitigar o deslocamento de domínio. A capacidade de generalização do modelo é avaliada de forma robusta via validação cruzada em cenários de classificação binária, de 3 classes e de 6 classes, utilizando o conjunto de dados CRIC [4]. Por fim, as predições são combinadas por meio de uma abordagem de *ensemble* por probabilidades, e os resultados obtidos são comparados com trabalhos correlatos da literatura a fim de validar a eficiência do método proposto. O código dos experimentos está no GitHub [12].

II. METODOLOGIA

A. Conjunto de Dados

O conjunto de dados utilizado neste trabalho provém da plataforma pública *CRIC Cervix* (*Center for Recognition and Inspection of Cells*), introduzida por Rezende et al. [4]. A base é composta por 400 imagens digitalizadas com dimensões de 1.376×1.020 pixels, capturadas a partir de lâminas reais de citopatologia convencional (exame de Papanicolaou). Ao todo, a coleção reúne 11.534 células identificadas e anotadas individualmente, com marcações computacionais centralizadas no núcleo de cada estrutura celular.

A classificação das células foi realizada estritamente sob as diretrizes e nomenclaturas padronizadas pelo Sistema de Bethesda. As classes e suas distribuições podem ser vistas na Figura 1.





Fig. 1: Distribuição das classes CIRC.

B. Processamento e Divisão do Conjunto de Dados

Cada linha dos metadados do conjunto de dados descreve a imagem na qual a célula está contida, sua respectiva classificação e as coordenadas (x, y) de seu núcleo. Visto que o classificador foi projetado para inferir a lesão individual de cada célula, e considerando que as imagens originais contêm múltiplas células, determinou-se empiricamente o tamanho de janela $n = 90$. A partir disso, foi realizado um recorte de $n \times n$ pixels centralizado no núcleo da célula, conforme ilustrado na Figura 2.



(a) Imagem original. (b) Recorte da imagem.

Fig. 2: Imagem original e o recorte de uma célula.

O conjunto de dados foi dividido na proporção de 80% das células para o conjunto de treino e 20% para o conjunto de teste. Adicionalmente, aplicou-se a validação cruzada sobre os dados de treino para a seleção de hiperparâmetros e ajuste do modelo, garantindo uma avaliação de desempenho mais robusta e mitigando o risco de sobreajuste (*overfitting*). Por fim, o conjunto de teste foi utilizado exclusivamente para a mensuração final da capacidade de generalização do classificador.

Para o conjunto de treino, aplicou-se um pipeline de aumento de dados (*data augmentation*) composto por redimensionamento para as dimensões de entrada da rede e

transformações geométricas, incluindo reflexões horizontais e verticais. Ademais, realizou-se a rotação aleatória em até 180° , justificável pelo fato de células citológicas não possuírem orientação canônica fixa. Para evitar que o modelo assumisse que o núcleo celular estaria sempre centralizado no recorte, aplicou-se um leve deslocamento e zoom (escala de 0.8 a 1.0). Por fim, inseriu-se uma perturbação de cor acentuada, alterando brilho, contraste e saturação em 0.3, e matiz (*hue*) em 0.05. Essa etapa é crítica para o cenário avaliado, pois mitiga o deslocamento de domínio (*domain shift*) provocado pelas variações nos protocolos de coloração de Papanicolaou entre as 400 lâminas originais, forçando a rede a aprender a morfologia celular em detrimento de padrões de cor locais. Os dados foram normalizados utilizando as médias e desvios padrão da ImageNet.

C. Modelo

Para a classificação das imagens de células cervicais, utilizou-se a arquitetura *EfficientNet-B3* [10], selecionada por sua eficiência e capacidade de extração de características morfológicas complexas através do escalonamento composto (*compound scaling*). O modelo foi inicializado com pesos pré-treinados no conjunto de dados ImageNet por meio de aprendizado por transferência (*transfer learning*).

A cabeça de classificação original da rede foi substituída por uma camada identidade, transformando a *backbone* em um extrator de características puro. Acoplada a essa saída, implementou-se uma nova estrutura sequencial composta por uma camada de *Dropout*, com probabilidade p definida via hiperparâmetro, e uma camada linear (*Fully Connected*) configurada para o número de classes do cenário avaliado ($num_classes \in \{2, 3, 6\}$).

O treinamento adota uma estratégia de congelamento seletivo por blocos. As camadas iniciais da rede permanecem congeladas, preservando os extratores de características genéricas (bordas e texturas). Apenas um número k de blocos finais é mantido treinável para permitir a adaptação do modelo às especificidades morfológicas das células do conjunto CRIC.

D. Treinamento

O processo de treinamento é conduzido de forma independente para cada uma das três tarefas avaliadas (classificação binária, 3 classes e 6 classes). Para garantir a comparabilidade direta entre os cenários, os mesmos splits de dados são mantidos em todas as frentes através de uma amostragem estratificada baseada no sistema Bethesda. O treinamento é dividido em duas etapas sequenciais:

- **Aquecimento (*Warm-up*):** Durante as duas primeiras épocas, a *backbone* do modelo permanece totalmente congelada. Essa fase visa ajustar exclusivamente a nova cabeça de classificação linear (inicializada aleatoriamente) sob uma taxa de aprendizado de 10^{-3} , evitando que os gradientes iniciais instáveis degradem os pesos pré-treinados.
- **Ajuste Fino (*Fine-Tuning*):** Nas épocas subsequentes, libera-se a totalidade da rede para treinamento ($k =$

None) sob uma taxa de aprendizado de 10^{-4} . Embora o congelamento das primeiras camadas seja comum para imagens naturais, experimentos empíricos preliminares indicaram que manter toda a estrutura móvel é crucial neste domínio.

Para a otimização dos parâmetros, emprega-se o algoritmo AdamW com decaimento de peso (*weight decay*) de 0,05 e tamanho de lote (*batch size*) igual a 32. Com o objetivo de mitigar o excesso de confiança da rede decorrente do desbalanceamento severo de amostras do conjunto CRIC, aplica-se a técnica de suavização de rótulos (*label smoothing*) com fator de 0,1 associada à estratégia de amostragem *sampler_sqrt* na montagem dos minilotes.

O processo de otimização e convergência do modelo é monitorado dinamicamente ao longo de até 100 épocas por meio de dois mecanismos complementares que avaliam a métrica de validação. O primeiro deles é o agendador de taxa de aprendizado *ReduceLROnPlateau*, o qual reduz o passo de otimização após uma paciência de 3 épocas consecutivas de estagnação, permitindo que a rede realize ajustes mais finos em seus pesos. Caso a ausência de melhorias persista por uma paciência expandida de 10 épocas, o critério de parada antecipada (*Early Stopping*) interrompe o treinamento de forma definitiva para evitar o *overfitting* e mitigar o desperdício de recursos computacionais.

Adicionalmente, com o intuito de garantir a estabilização estatística do modelo na fase inicial de aquecimento (*warm-up*), o método força o uso do modo de avaliação nas camadas de normalização por lote (*Batch Normalization*) que foram fixadas, congelando as médias e variâncias móveis para prevenir que os gradientes instáveis desse período inicial introduzam distorções deletérias nas estatísticas da rede.

A robustez estatística dos resultados é assegurada por meio de uma validação cruzada com $K = 5$ *folds* aplicada sobre o conjunto de treino, permitindo o cálculo explícito de desvios padrão para os valores reportados. Após a convergência, os pesos salvos de cada um dos 5 *folds* são utilizados em conjunto para inferir sobre a parcela de teste intocada através de uma abordagem de *ensemble*, gerando as métricas definitivas de generalização do classificador.

E. Avaliação e Métricas

O conjunto de teste, segregado inicialmente e mantido completamente intocado durante as etapas de treinamento e ajuste de hiperparâmetros, é submetido à avaliação final através de uma abordagem baseada em comitê de modelos (*ensemble*). Como o processo de validação cruzada gera $K = 5$ modelos distintos (um para cada *fold*), a mensuração da capacidade de generalização na parcela de teste é reportada sob duas perspectivas complementares:

- **Desempenho Agregado Individual:** Calcula-se de forma explícita a média (μ) e o desvio padrão (σ) das métricas obtidas por cada um dos 5 modelos avaliados de forma isolada. Essa abordagem garante uma estimativa estatisticamente honesta do comportamento esperado de uma

única rede sob a configuração proposta, mapeando a estabilidade do treinamento frente a flutuações amostrais.

- **Predição por Comitê (*Ensemble*):** Constrói-se um classificador unificado combinando as predições de todas as redes treinadas. Diferente de uma votação majoritária simples baseada em rótulos discretos, a estratégia de fusão adota a média aritmética das probabilidades contínuas geradas pela função de ativação *Softmax*, conforme descrito por:

$$P_{\text{ensemble}}(y = c | x) = \frac{1}{K} \sum_{i=1}^K P_i(y = c | x) \quad (1)$$

em que $P_i(y = c | x)$ representa a probabilidade atribuída pelo i -ésimo modelo à classe c para uma imagem de entrada x . O rótulo final do *ensemble* corresponde à classe com maior probabilidade agregada (*argmax*). Esse método, conhecido como votação ponderada suave (*soft voting*), confere maior peso aos modelos que exibem alto grau de certeza em suas predições e atenua a influência de redes inseguras, resultando em um sistema de predição mais robusto e resiliente.

O desempenho final é quantificado a partir das métricas globais de Acurácia, Precisão Macro, Sensibilidade (*Recall*) Macro e, prioritariamente, o *F1-Score* Macro. A escolha de métricas com agrupamento macro é indispensável para este domínio citológico, dado que elas atribuem pesos idênticos a todas as classes durante o cálculo da média, impedindo que o excelente desempenho em classes majoritárias mascare eventuais falhas do modelo na detecção de lesões raras ou de alta gravidade (classes minoritárias).

III. RESULTADOS E DISCUSSÕES

Esta seção apresenta e discute os principais resultados obtidos na realização dos experimentos para os três cenários avaliados, considerando a aplicação de métricas balanceadas por meio da média ponderada (*weighted avg*).

A. Cenário de Classificação Duas Classes

Aqui apenas o modelo foi treinado para classificar entre duas classes: **sem lesão**, que é a classe *Negative for intraepithelial lesion*, e **com lesão**, que é formada pelas classes SCC, LSIL, HSIL, ASC-H, ASC-US. A Tabela I e a Figura 3 mostram os resultados deste cenário.

Neste cenário simplificado, o modelo demonstrou alto desempenho, alcançando estabilidade entre os *folds* com baixo desvio padrão. A abordagem por *ensemble* superou a média dos modelos individuais no teste, elevando o *F1-Score* ponderado (*weighted avg*) para 0,9285 e a acurácia global para 92,85%. Isso evidencia que a combinação das probabilidades suavizou erros ortogonais das redes individuais, garantindo um classificador binário altamente confiável para a triagem inicial de lesões.

TABLE I: Resultados obtidos para o cenário de duas classes.

Métrica	Validação Cruzada (Média $\pm \sigma$)	Modelos Individuais no Teste	Ensemble (Teste Final)
F1-Score	0,9113 $\pm$ 0,0161	0,9192 $\pm$ 0,0040	0,9285
Precisão	0,9120 $\pm$ 0,0164	0,9199 $\pm$ 0,0041	0,9285
Recall	0,9113 $\pm$ 0,0162	0,9190 $\pm$ 0,0039	0,9285
Acurácia	0,9113 $\pm$ 0,0162	0,9190 $\pm$ 0,0039	0,9285




Fig. 3: Matriz de confusão ensemble para duas classes.

B. Cenário de Classificação Três Classes

Neste cenário, as células são categorizadas em três níveis de gravidade: **Negative**, **Low grade** (baixo grau) e **High grade** (alto grau). Esse agrupamento unifica classes limítrofes do Sistema de Bethesda para reduzir o ruído de rótulos causado por categorias clinicamente ambíguas.

A classe *Negative* contém apenas células normais. A classe *Low grade* funde as lesões de baixo grau (LSIL) às células escamosas atípicas de significado indeterminado (ASC-US). Já a classe *High grade* engloba as lesões de alto grau (HSIL), o carcinoma de células escamosas (SCC) e as células atípicas onde não se pode excluir alto grau (ASC-H). Os resultados são apresentados na Tabela II e na Figura 4.

Ao expandir o problema para três classes, observa-se uma redução esperada nas métricas devido ao aumento da complexidade da tarefa. Contudo, a estratégia de agrupar as classes limítrofes surtiu o efeito desejado, contendo a queda de desempenho. O *ensemble* alcançou um *F1-Score* ponderado de 0,9031 no teste final, mantendo métricas equilibradas de precisão e sensibilidade (*weighted avg*), além de uma acurácia sólida de 90,30%.

TABLE II: Resultados obtidos para o cenário de três classes.

Métrica	Validação Cruzada (Média $\pm \sigma$)	Modelos Individuais no Teste	Ensemble (Teste Final)
F1-Score	0,8787 $\pm$ 0,0121	0,8803 $\pm$ 0,0080	0,9031
Precisão	0,8807 $\pm$ 0,0122	0,8831 $\pm$ 0,0077	0,9031
Recall	0,8798 $\pm$ 0,0120	0,8790 $\pm$ 0,0075	0,9030
Acurácia	0,8798 $\pm$ 0,0120	0,8790 $\pm$ 0,0075	0,9030




Fig. 4: Matriz de confusão ensemble para três classes.

C. Cenário de Classificação Seis Classes

Neste cenário, o modelo foi treinado para separar as 6 classes presentes no dataset CRIC individualmente. A Tabela III e a Figura 5 resumizam o desempenho obtido.

TABLE III: Resultados obtidos para o cenário de seis classes.

Métrica	Validação Cruzada (Média $\pm \sigma$)	Modelos Individuais no Teste	Ensemble (Teste Final)
F1-Score	0,7777 $\pm$ 0,0324	0,8057 $\pm$ 0,0083	0,8267
Precisão	0,7913 $\pm$ 0,0252	0,8105 $\pm$ 0,0067	0,8279
Recall	0,7801 $\pm$ 0,0280	0,8064 $\pm$ 0,0087	0,8289
Acurácia	0,7801 $\pm$ 0,0280	0,8064 $\pm$ 0,0087	0,8289




Fig. 5: Matriz de confusão ensemble para seis classes.

O cenário com seis classes lineares apresentou o maior desafio analítico, refletido na redução do *F1-Score* ponderado do *ensemble* para 0,8267. Essa queda é justificada pelo desbalanceamento severo das classes minoritárias e pela sutil diferenciação morfológica entre categorias semelhantes (como ASC-US e LSIL). Apesar disso, o *ensemble* novamente provou sua eficácia ao registrar um ganho expressivo em relação à média ponderada dos modelos individuais (0,8057), sustentando uma acurácia de 82,89%.

IV. COMPARAÇÃO COM OUTROS TRABALHOS

Para validar a eficácia do modelo proposto, realizou-se uma análise comparativa com estudos correlatos da literatura que também utilizaram o conjunto de dados CRIC para a classificação de células cervicais. A Tabela IV consolida os resultados reportados por diferentes abordagens em cenários equivalentes de duas, três e seis classes.

TABLE IV: Comparação de resultados com outros trabalhos

Trabalho	Técnica	Classes	Precisão (%)	Recall (%)	F1-score (%)	Acurácia (%)
[7]	KNN, RF	Two	89.70	91.70	90.70	89.70
		Three	85.10	95.40	89.90	85.10
	SVM	Two	96.00	96.00	96.00	95.69
[11]	Ensemble	Three	94.00	94.00	94.00	92.69
		Six	85.00	85.00	85.00	84.61
		Two	94.00	92.00	93.00	96.07
[9]	Feature Fusion	Three	91.00	92.00	91.00	93.30
		Six	81.00	82.00	81.00	85.07
		Two	92.85	92.85	92.85	92.85
Nosso Trabalho	Ensemble	Three	90.31	90.31	90.30	90.30
		Six	82.67	82.79	82.89	82.89
		Two	92.85	92.85	92.85	92.85

Os resultados demonstram que a abordagem proposta neste trabalho é competitiva, superando o estudo de [7] no cenário binário em todas as métricas analíticas (*F1-score* ponderado de 92,85% contra 90,70%). No cenário de três classes, embora [7] reporte um *Recall* superior, nosso modelo obteve uma acurácia global significativamente mais alta (90,30% contra 85,10%), evidenciando um equilíbrio superior entre a taxa de falsos positivos e falsos negativos.

Ao comparar com os trabalhos de [11] e [9], observa-se que estes apresentam métricas balanceadas (Precisão, *Recall* e *F1-score* em *weighted avg*) superiores, especialmente no complexo cenário de seis classes. No entanto, o modelo baseado em EfficientNet-B3 aqui desenvolvido manteve patamares de acurácia global muito próximos (82,89% frente a 84,61% e 85,07%).

V. CONCLUSÃO

Este trabalho apresentou uma abordagem baseada em aprendizado profundo utilizando a arquitetura EfficientNet-B3 para a classificação automatizada de células cervicais a partir de imagens do conjunto de dados CRIC. Através da implementação de estratégias de ajuste fino total combinadas com regularizações robustas, como perturbação de cor e suavização de rótulos (*label smoothing*), buscou-se mitigar os efeitos do deslocamento de domínio causados por variações de coloração nas lâminas.

Os experimentos demonstram que o uso de um comitê de modelos (*ensemble*) por votação suave superou de maneira consistente a média dos classificadores individuais. O método alcançou alto desempenho no cenário binário (*F1-Score* ponderado de 92,85%) e manteve-se sólido no cenário de três classes (*F1-Score* ponderado de 90,31%), provando ser uma alternativa confiável para a triagem inicial e categorização por níveis de gravidade. No cenário mais complexo de seis classes, apesar do desbalanceamento severo e da similaridade morfológica limítrofe, o modelo ainda sustentou um *F1-Score* ponderado competitivo de 82,67%.

REFERENCES

- [1] M. Ervik, M. Laversanne, F. Lam, M. Colombet, J. Ferlay, A. M. Filho, and F. Bray, "Global Cancer Observatory: Cancer Today (2024 estimates, version 1.0)," International Agency for Research on Cancer, Lyon, France, July 2026. [Online]. Available: <https://gco.iarc.who.int>. Data version: GLOBOCAN 2024 - 08.07.2026.
- [2] A. Meggiolaro, B. Unim, L. Semyonov, S. Miccoli, E. Maffongelli, and G. La Torre, "The role of Pap test screening against cervical cancer: a systematic review and meta-analysis," Clin Ter, vol. 167, no. 4, pp. 124–139, 2016.
- [3] P. L. Sachan, M. Singh, M. L. Patel, and R. Sachan, "A Study on Cervical Cancer Screening Using Pap Smear Test and Clinical Correlation," Asia-Pacific Journal of Oncology Nursing, vol. 5, no. 3, pp. 337–341, 2018. doi: 10.4103/apjon.apjon_15_18.
- [4] M. T. Rezende, R. Silva, F. de O. Bernardo, A. H. G. Tobias, P. H. C. Oliveira, T. M. Machado, C. S. Costa, F. N. S. Medeiros, D. M. Ushizima, C. M. Carneiro, and A. G. C. Bianchi, "Cric searchable image database as a public platform for conventional pap smear cytology data," Scientific Data, vol. 8, no. 151, pp. 1–8, June 2021. doi: 10.1038/s41597-021-00933-8.

- [5] S. B. N. Tavares, N. L. A. de Souza, E. J. C. Manrique, C. Z. S. Ázara, E. A. da Silveira, and R. G. Amaral, "Internal Quality Control for Cervical Cytopathology: Comparison of Potential False-Negatives Detected at Rapid Prescreening and at 100% Rapid Review," *Acta Cytologica*, vol. 58, no. 5, pp. 439–445, November 2014. doi: 10.1159/000368041.
- [6] K. Shailaja, B. Seetharamulu, and M. A. Jabbar, "Machine Learning in Healthcare: A Review," in *Proceedings of the 2018 Second International Conference on Electronics, Communication and Aerospace Technology (ICECA)*, 2018, pp. 910–914. doi: 10.1109/ICECA.2018.8474918.
- [7] R. Silva, F. Araújo, M. Rezende, P. Oliveira, F. Medeiros, R. Veras, and D. Ushizima, "Searching for cell signatures in multidimensional feature spaces," *International Journal of Biomedical Engineering and Technology*, vol. 36, no. 3, pp. 236–256, 2021. doi: 10.1504/IJBET.2021.116988.
- [8] E. Hussain, L. B. Mahanta, C. R. Das, and R. K. Talukdar, "A comprehensive study on the multi-class cervical cancer diagnostic prediction on pap smear images using a fusion-based decision from ensemble deep convolutional neural network," *Tissue and Cell*, vol. 65, p. 101347, 2020. doi: 10.1016/j.tice.2020.101347.
- [9] R. K. Madhukar, R. C. Joshi, and M. K. Dutta, "A Robust Deep Learning and Feature Fusion-based Multi-class Classification of Cervical Cells," in *Proceedings of the 2022 International Conference on Edge Computing and Applications (ICECAA)*, 2022, pp. 1269–1275. doi: 10.1109/ICECAA55415.2022.9936276.
- [10] M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," in *Proc. 36th Int. Conf. Mach. Learn.*, Long Beach, California, PMLR 97, 2019.
- [11] D. N. Diniz, M. J. F. Souza, C. M. Carneiro, D. M. Ushizima, F. N. S. de Medeiros, P. H. C. Oliveira, and A. G. C. Bianchi, "An Iterated Local Search-Based Algorithm to Support Cell Nuclei Detection in Pap Smears Test," in *Enterprise Information Systems*. Cham: Springer International Publishing, 2020, pp. 78–96.
- [12] intel-comp-saude-ufes/2026-1-P-cell-classification, "Classificação de Células Cervicais em Imagens de Citologia Baseada em Redes Neurais Convolucionais," *Inteligência Computacional em Saúde*, Universidade Federal do Espírito Santo (UFES), 2026. [Online]. Disponível em: <https://github.com/intel-comp-saude-ufes/2026-1-P-cell-classification>